

# MCTS Aplicado a Activos Financieros

Marco Matemático y Referencias

1 de abril de 2026

## 1. Formulación como Proceso de Decisión de Markov

El problema se modela como un MDP definido por la tupla  $(S, A, T, R, \gamma)$ :

- **Estado**  $s_t = (P_t, C_t, H_t)$ : precio de cierre del activo, capital líquido disponible y acciones en cartera en el instante  $t$ .
- **Acciones**  $a_t \in \{-k\%, 0, +k\%\}$ : vender, mantener o comprar un porcentaje  $k$  del capital.
- **Recompensa**  $R_t = \ln\left(\frac{V_t}{V_{t-1}}\right)$ , donde el valor total del portafolio es  $V_t = C_t + H_t \cdot P_t$ .

## 2. Selección — Política UCT

Cada nodo del árbol de decisión se trata como una instancia del problema del bandido multi-brazo. La política **UCT** (*Upper Confidence Bounds for Trees*) selecciona la acción que maximiza:

$$a^* = \arg \max_a \left[ Q(s, a) + c \sqrt{\frac{\ln N(s)}{n(s, a)}} \right]$$

donde  $Q(s, a)$  es la recompensa media observada (**explotación**), el segundo término incentiva la **exploración** de acciones poco visitadas,  $N(s)$  es el número total de visitas al nodo padre,  $n(s, a)$  el número de visitas a la acción  $a$  desde  $s$ , y  $c$  la constante de exploración.

El algoritmo **UCB1** subyacente garantiza un arrepentimiento (*regret*) de orden  $O(\log n)$ , óptimo para el problema de bandido.

## 3. Simulación (Rollout) con Movimiento Browniano Geométrico

En lugar de una política de rollout aleatoria, la trayectoria futura del precio se simula mediante el **GBM**:

$$P_{t+1} = P_t \cdot \exp \left[ \left( \mu - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z \right], \quad Z \sim \mathcal{N}(0, 1)$$

Para el activo de referencia (TSLA):  $\mu \approx 0,03\%$  diario y  $\sigma \approx 1,8\%$  diario, estimados con datos históricos.

## 4. Convergencia Teórica

**Teorema de convergencia de UCT** (Kocsis & Szepesvári, 2006): cuando el número de iteraciones tiende a infinito, la probabilidad de seleccionar una acción subóptima en la raíz tiende a cero.

**Hipótesis y advertencias críticas:**

- **H2 — Recompensas acotadas:** las garantías teóricas exigen  $R_t \in [0, 1]$ . Es necesario *normalizar* los retornos logarítmicos a ese intervalo para aplicar las cotas de Hoeffding.
- **H8 — Varianza finita:** necesaria para que la ley de los grandes números opere al promediar rollouts. Las colas pesadas del mercado ralentizan la convergencia; la solución propuesta es sustituir el GBM por una *red neuronal* entrenada con datos históricos (arquitectura AlphaZero).

## 5. Referencias Clave

| Categoría                    | Referencia                                                                                |
|------------------------------|-------------------------------------------------------------------------------------------|
| Fundamentos UCB              | Auer, P. et al. (2002). <i>Finite-time analysis of the multiarmed bandit problem</i> .    |
| Cota inferior óptima         | Lai, T. L. & Robbins, H. (1985).                                                          |
| Exploración-explotación      | Lilian Weng, <i>The Multi-Armed Bandit Problem</i> (blog).                                |
| <b>Texto fundacional UCT</b> | <b>Kocsis, L. &amp; Szepesvári, C. (2006).</b> <i>Bandit based Monte-Carlo Planning</i> . |
| Survey completo              | Browne, C. et al. (2012). <i>A Survey of Monte Carlo Tree Search Methods</i> .            |
| AlphaGo / AlphaZero          | Silver, D. et al. (2016, 2018). Artículos en <i>Nature</i> y <i>Science</i> .             |
| Implementación práctica      | Int8, <i>Beginner's Guide to MCTS</i> (guía Python).                                      |

El texto fundacional indispensable es **Kocsis & Szepesvári (2006)**, que establece UCT y su teorema de convergencia. La extensión natural hacia AlphaZero (Silver et al.) es relevante si se reemplazan los rollouts GBM por una función de valor aprendida.