

Monte Carlo Tree Search aplicado a decisiones de inversión financiera

Un estudio sobre el activo TSLA

Héctor Orosa, Sofía Ortiz, Carlos Ruiz

Universidad de Valencia
Métodos Numéricos

1 de mayo de 2026

Contenido

- 1 Introducción y objetivos
- 2 Fundamento teórico
- 3 Implementación en Python
- 4 Resultados
- 5 Discusión y conclusiones

El problema

Cada sesión bursátil un inversor decide **comprar, vender o mantener** un activo disponiendo únicamente de información histórica y una estimación del futuro.

Este es un **proceso de decisión secuencial bajo incertidumbre**:

- El estado futuro es desconocido.
- Se pueden asignar *probabilidades* a sus evoluciones.
- Se busca *maximizar el valor esperado* de un objetivo.

Pregunta guía

¿Existe una política $\pi : \mathcal{S} \rightarrow \mathcal{A}$ que obtenga sistemáticamente un retorno superior al de la estrategia pasiva *Buy & Hold*?

Herramientas

- Variables aleatorias
- Simulación estocástica
- Estimación por media muestral

Conexión con el Monte Carlo clásico

Idea central

El MCTS es una **aplicación directa** del estimador de Monte Carlo por media muestral.

Si X_i es el retorno al simular una trayectoria de precios durante H días tomando la acción a , repitiéndolo n veces de forma independiente:

$$\hat{l}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{c.s.}} \mathbb{E}[X \mid a] \quad (n \rightarrow \infty)$$

por la **Ley Fuerte de los Grandes Números**.

En cada nodo del MCTS:

$$\frac{Q(a)}{N(a)} \Leftrightarrow \hat{l}_n$$

aplicado a los rollouts ejecutados hasta ese momento.

Objetivos del trabajo

- 01 Formalizar** el problema de trading como un Proceso de Decisión de Markov (MDP) con espacio de acciones discreto.
- 02 Implementar** el algoritmo MCTS con política UCB1 y rollouts generados mediante Movimiento Browniano Geométrico (GBM) calibrado sobre ventana móvil.
- 03 Demostrar** que la convergencia se apoya en la LLN y en la cota de error $\mathcal{O}(n^{-1/2})$.
- 04 Comparar** MCTS con Buy & Hold mediante ROI, Sharpe, alfa y drawdown.
- 05 Validar** experimentalmente la cota $\mathcal{O}(n^{-1/2})$ observando la convergencia del árbol.

Monte Carlo por media muestral

Estimador

Sea X v.a. con $\mathbb{E}[X] = \mu$ finita. Dadas $X_1, \dots, X_n$ i.i.d.:

$$\hat{I}_n = \frac{v}{n} \sum_{i=1}^n X_i$$

donde v es el volumen del dominio de integración.

Cota de error

Por el TCL, para n suficientemente grande:

$$\varepsilon_n = \frac{v \sigma}{\sqrt{n}} z_{\alpha/2} = \mathcal{O}(n^{-1/2})$$

donde $\sigma^2 = \text{Var}(X)$.

Ley Fuerte de los Grandes Números

$$\hat{I}_n \xrightarrow{\text{c.s.}} v \cdot \mu \quad (n \rightarrow \infty)$$

Implicación para MCTS

Doblar la precisión requiere **cuadruplicar** las iteraciones. Justifica elegir
ITERACIONES = 5,000.

Proceso de Decisión de Markov (MDP)

Definición

Un MDP es una cuádrupla $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R)$:

- $\mathcal{S}$: espacio de **estados**
- $\mathcal{A}$: espacio de **acciones**
- $P(s' | s, a)$: **núcleo de transición** (distribución del estado siguiente)
- $R : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$: **función de recompensa**

La **propiedad de Markov**: $S_{t+1} \perp \text{pasado} \mid (S_t, A_t)$.

Política y función de valor:

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t R(S_t, A_t) \mid S_0 = s \right]$$

Ecuación de Bellman:

$$V^*(s) = \max_{a \in \mathcal{A}} \left\{ R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right\}$$

Resolver Bellman directamente requiere *enumerar* $\mathcal{S} \rightarrow$ inviable en trading. MCTS lo esquiva mediante simulación estocástica.

El MDP del trading sobre TSLA

Estado $s_t = (P_t, MA_{20}, RSI_{14}, \tau_t, C_t, N_t)$:

- P_t : precio de cierre
- MA_{20} : media móvil 20 días
- RSI_{14} : Relative Strength Index
- C_t : efectivo disponible
- N_t : acciones poseídas


Recompensa terminal:

$$R_T = \ln \frac{V_T^{\text{MCTS}}}{V_T^{\text{B\&H}}}$$

Espacio de acciones $\mathcal{A}$ (11 elementos):

COMPRAR 100 %
COMPRAR 75 %
COMPRAR 50 %
COMPRAR 25 %
COMPRAR 10 %
MANTENER
VENDER 10 %
VENDER 25 %
VENDER 50 %
VENDER 75 %
VENDER 100 %

Los 4 pasos del MCTS



Al final: elegir $\arg \max_a N(s_0, a)$ (**política max-visits**, más robusta que max- Q)

UCB1: dilema exploración–explotación

Fórmula UCB1 (Kocsis & Szepesvári, 2006)

$$a_{\text{UCB1}}^*(s) = \arg \max_{a \in \mathcal{A}(s)} \left\{ \underbrace{\frac{Q(s, a)}{N(s, a)}}_{\text{explotación}} + \sqrt{2} \underbrace{\sqrt{\frac{\ln N(s)}{N(s, a)}}}_{\text{exploración}} \right\}$$

Término de explotación

Favorece acciones con **alta recompensa media** ya observada.



Término de exploración

Favorece acciones **poco visitadas**: si $N(s, a)$ se mantiene acotado mientras $N(s) \rightarrow \infty$, el término diverge $\rightarrow$ toda acción se visita infinitas veces.

MCTS con UCB1 es un método iterativo tipo **Gauss–Seidel adaptativo**: actualiza una sola componente $q^{(k)}(a)$ por iteración, eligiendo la componente mediante la fórmula UCB1 en lugar de un orden cíclico.

NO !!!!!!!!Analogía Gauss–Seidel y convergencia $\mathcal{O}(N^{-1/2})$

Patrones de actualización: $x_i^{(k+1)}$ en métodos iterativos



Regla de actualización (iteración k)

$$q^{(k+1)}(a) = (1 - \alpha_k) q^{(k)}(a) + \alpha_k X_{k+1}, \quad \alpha_k = \frac{1}{N^{(k)}(a)+1}$$

MCTS elige adaptativamente *qué* acción actualizar mediante UCB1, en lugar del orden cíclico de Gauss–Seidel. El parámetro $c = \sqrt{2}$ hace el papel de la relajación ω en SOR.

Cota de error del estimador Monte Carlo

$$|e^{(k)}(a)| = |q^{(k)}(a) - \mathbb{E}[R_T | s_0, a]| = \mathcal{O}(N^{-1/2})$$

La pendiente $-\frac{1}{2}$ en escala log-log confirma que el error decae como el del estimador de Monte Carlo. UCB1 garantiza $N(a) \rightarrow \infty$ para toda acción (aplicabilidad de LLN).

Movimiento Browniano Geométrico (GBM)

Motor de simulación del rollout. Bajo la hipótesis de log-retornos gaussianos el precio satisface:

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

Solución exacta (Lema de Itô)

$$S_{t+h} = S_t \exp\left(\left(\mu - \frac{\sigma^2}{2}\right)h + \sigma\sqrt{h}Z\right), \quad Z \sim \mathcal{N}(0,1)$$

Sin error de discretización (solución analítica, no Euler–Maruyama).

Calibración rolling

$(\hat{\mu}, \hat{\sigma})$ estimados sobre los últimos VENTANA_CALIB= 60 días de log-retornos:

$$r_k = \ln \frac{P_k}{P_{k-1}}$$

Sin lookforward bias: solo se usan datos pasados.

Convergencia del MCTS

Argumento

Para cada acción $a \in \mathcal{A}$, UCB1 garantiza $N(s_0, a) \rightarrow \infty$ conforme el total de iteraciones $n \rightarrow \infty$. Por el Corolario de la LLN:

$$\frac{Q(s_0, a)}{N(s_0, a)} \xrightarrow{\text{c.s.}} \mathbb{E}[R_T \mid s_0, a]$$

Error del estimador

Recurrencia lineal con $\alpha_k = 1/(N^{(k)}(a) + 1)$:

$$q^{(k+1)}(a) = (1 - \alpha_k) q^{(k)}(a) + \alpha_k X_{k+1}$$

La varianza decae:

$$\text{Var}(e^{(k)}) = \sigma^2(a)/N^{(k)}(a) = \mathcal{O}(N^{-1}), \text{ luego error} \\ = \mathcal{O}(N^{-1/2}).$$

MCTS como método iterativo:

Tema 6	MCTS
Iterado $x^{(k)}$	$q^{(k)}(a)$
Solución x^*	$\mathbb{E}[R_T \mid s_0, a]$
Término indep. b	Retorno X_{k+1}
Matriz iteración Q	$1 - \alpha_k$
$\rho(Q) < 1$	$ 1 - \alpha_k < 1 \checkmark$
Gauss–Seidel	MCTS con UCB1
Relajación ω	Exploración c

NO !!!Estructura del código

Archivo: mcts_simple_TSLA.py

§1 Descarga de datos (yfinance)

§2 Espacio de acciones (11)

§3 Señales técnicas (RSI, MA20)

§4 Estado de la cartera

§4 Calibración GBM (rolling)

§5 Los 4 pasos del MCTS

§6 Bucle principal MCTS

§7 Backtest día a día

§8 Métricas financieras

§9--10 Visualización (4 figuras)

Parámetros globales:

```
TICKER      = "TSLA"  
PERIOD      = "2y"      # ~506 sesiones  
CAPITAL_INIT = 10_000    # USD  
ITERACIONES = 1_000     # por decision  
DIAS_ROLLOUT = 60       # horizonte GBM  
VENTANA_CALIB = 60      # dias rolling  
SEMILLA     = 42        # reproducibilidad
```

Flujo principal

- 1 Descargar precios históricos
- 2 Para cada día: ejecutar MCTS
- 3 Aplicar acción con precio real
- 4 Registrar evolución de la cartera
- 5 Comparar con Buy & Hold

NO !!!Funciones clave: estado y calibración GBM

Estado de la cartera:

```
def crear_estado(dia, efectivo,
                 acciones, precio,
                 precios_hist=None):
    rsi = calcular_rsi(precios_hist, dia)
    ma20 = calcular_ma(precios_hist, dia)
    return {
        "dia": dia,
        "efectivo": efectivo,
        "acciones": acciones,
        "precio": precio,
        "rsi": rsi,
        "ma20": ma20,
    }
```

El valor total es: $C_t + N_t \cdot P_t$

Calibración GBM (rolling):

```
def calibrar_gbm(precios, dia):
    inicio = max(0, dia - VENTANA_CALIB)
    ventana = precios[inicio:dia+1]
    log_ret = np.diff(np.log(ventana))
    mu = float(np.mean(log_ret))
    sigma = float(np.std(log_ret, ddof=1))
    return mu, sigma
```

Simulación GBM exacta:

```
precio_futuro = precio_actual * exp(
    (mu_a - 0.5*sigma_a**2)*T
    + sigma_a * sqrt(T) * Z
) # Z ~ N(0,1)
```

NO !!!Funciones clave: los 4 pasos

UCB1:

```
def ucb1(nodo, c=math.sqrt(2)):  
    if nodo["n"] == 0:  
        return float("inf")  
    expl = nodo["w"] / nodo["n"]  
    padre = nodo["padre"]  
    expl += c * sqrt(  
        log(padre["n"]) / nodo["n"]  
    )  
    return expl
```

Selección:

```
def seleccionar(raiz, acc_posibles):  
    nodo = raiz  
    while not acciones_no_exploradas(  
        nodo, acc_posibles) \  
        and nodo["hijos"]:  
        nodo = max(nodo["hijos"],  
                    key=ucb1)  
    return nodo
```

Rollout (recompensa relativa):

```
# Mismo Z para agente y B&H: justo  
Z = rng.standard_normal()  
precio_sim = estado["precio"] * exp(  
    (mu_a - 0.5*sigma_a**2)*T  
    + sigma_a*sqrt(T)*Z  
)  
log_ret_agente = log(valor_agente /  
                    valor_inicial)  
log_ret_bah = log(precio_sim /  
                  precio_actual)  
recompensa = log_ret_agente - log_ret_bah
```

Retropropagación:

```
def retropropagar(nodo, recompensa):  
    while nodo is not None:  
        nodo["n"] += 1  
        nodo["w"] += recompensa  
        nodo = nodo["padre"]
```

Decisiones de diseño relevantes

Recompensa relativa vs. absoluta

Recompensa = exceso de log-retorno del agente sobre B&H. Si mercado sube 5 % y agente sube 3 %, recompensa = -2 %: penaliza estar poco invertido en mercado alcista.

Filtro de acciones viables (`acciones_viables`)

Sin efectivo $\rightarrow$ excluye COMPRAR; sin acciones $\rightarrow$ excluye VENDER. Evita que VENDER con posición vacía compita con MANTENER y sea coronada erróneamente por el ruido de los rollouts.

Common Random Numbers en el rollout

Agente y B&H usan el **mismo** $Z \sim \mathcal{N}(0, 1)$: misma trayectoria de mercado, solo cambia la decisión. Reduce la varianza de la estimación comparativa.

Política de selección final: max-visits

Se elige $\arg \max_a N(s_0, a)$ en lugar de $\arg \max_a Q/N$. Con Q/N alto pero N pequeño el error estándar $\sigma/\sqrt{N}$ es grande $\rightarrow$ max-visits es estadísticamente más robusta.

Configuración experimental


Activo	TSLA (Tesla, Inc.)
Periodo	2 años (≈ 506 sesiones)
Capital inicial	10 000 USD
ITERACIONES	5 000
DIAS_ROLLOUT	60
VENTANA_CALIB	60 días
SEMILLA	42

Contexto del mercado

Periodo de altísima volatilidad:

- Precio: $\approx 150\$ \rightarrow \approx 480\$$ (máx., día 170)
- Corrección severa: $\approx -75\%$ (día 230)
- Recuperación al máximo (día 420)
- Cierre: $\approx 350\$$
- Volatilidad diaria media: 1,903 %
($\approx 30,2\%$ anualizada)

Precio del activo y evolución de la cartera




Señales de decisión MCTS

▲ COMPRAR / ▼ VENDER en cada sesión.

En el tramo bajista (días 150–230) predominan las ventas; en el alcista, las compras. La política adapta la exposición al régimen detectado por el GBM con ventana móvil.


Precio del activo y evolución de la cartera



Valor de la Cartera: $V_t = C_t + N_t \cdot P_t$

La gestión activa de **MCTS** **preserva el capital** mientras B&H sufre la caída completa.

Ventaja relativa sobre B&H: Alfa



$$\text{Alfa (exceso de retorno): } \alpha_t = \left(\frac{V_t^{\text{MCTS}}}{V_t^{\text{B\&H}}} - 1 \right) \times 100 \%$$

- Alfa positivo : MCTS supera al mercado.
- Pico $\approx +80 \%$ tras el mínimo de la corrección.
- La alfa tiende a **crecer**.

Precio del activo y evolución de la cartera




Señales de decisión MCTS

Señales diferenciadas por intensidad: ▲ COMPRAR100 % vs. ▼ VENDER 100 %..

La política binaria predomina ↔ operaciones parciales son minoritarias.


Exposición dinámica al activo



Ratio de exposición

MCTS aprende una política **todo-o-nada**: $\rho_t \approx 0$ o $\rho_t \approx 1$. B&H mantiene $\rho = 1$ constante (línea naranja).
Exposición media MCTS $\approx 60\%$.

Ventaja relativa sobre B&H: Drawdown




$$\text{Drawdown máximo: } DD_t = \frac{V_t - \max_{s \leq t} V_s}{\max_{s \leq t} V_s} \times 100\%$$

MCTS: $\approx -10\%$ vs. B&H: $\approx -75\%$.

- Salida al efectivo antes de la corrección limita drásticamente la caída máxima.


Convergencia UCB1



$$\frac{Q(a)}{N(a)} \xrightarrow{\text{c.s.}} \mathbb{E}[R_T | s_0, a] \quad (LLN)$$

Las líneas se estabilizan en ≈ 500 iteraciones. La envolvente decrece $\propto N^{-1/2}$, validando la cota teórica del estimador de Monte Carlo.

NO !!!Distribución de retornos diarios



MCTS
Media: +0.260%
Mediana: +0.000%
Std: 2.679%
Min: -11.101%
Max: +14.664%
Sesgo: +0.443
Días >0: 199 (39.8%)

Buy & Hold
Media: +0.205%
Mediana: +0.092%
Std: 3.840%
Min: -15.426%
Max: +22.690%
Sesgo: +0.631
Días >0: 256 (51.2%)

Retorno diario y Sharpe anualizado

$$r_t = \frac{V_t - V_{t-1}}{V_{t-1}}, \quad \text{Sharpe} = \frac{\bar{r}}{\hat{\sigma}_r} \sqrt{252}$$

Mediana MCTS = 0 (días en efectivo). Asimetría positiva: cola derecha más larga que la izquierda, coherente con la política de *market timing*.

Estadísticas comparativas

MCTS: media +0,302 %, std 3,07 %, Sharpe $\approx 1,56$.

B&H: media +0,232 %, std 1,90 %, Sharpe $\approx 1,93$.

Mayor retorno medio a costa de mayor volatilidad.

Métricas comparativas

Métrica	MCTS	Buy & Hold
ROI total	$\approx +240\%$	$\approx +100\%$
Retorno diario medio	+0,302 %	+0,232 %
Desv. típica diaria	3,065 %	1,903 %
Sharpe anualizado	$\approx 1,56$	$\approx 1,93$
Días con retorno > 0	216 (43.3 %)	254 (50.9 %)
Drawdown máximo	$\approx -10\%$	$\approx -75\%$
Alfa final vs. B&H	$\approx +40\%$	—

Tensión principal

MCTS supera a B&H en retorno total (+240 % vs. +100 %) pero tiene **Sharpe inferior** (1,56 vs. 1,93). La política binaria implica mayor volatilidad diaria, pero el drawdown máximo es solo -10% frente al -75% de B&H.

GBM con colas ligeras

L1

Los log-retornos gaussianos subestiman eventos extremos (*fat tails*). La caída -75% de TSLA ocurre en la realidad con mucha más frecuencia de la que predice el modelo. Extensión natural: modelo de Merton (GBM + saltos de Poisson).

Validez limitada al periodo analizado

L2

Los hiperparámetros no se han separado en *in-sample* / *out-of-sample*, y TSLA en este periodo es especialmente favorable para *market timing*. Una evaluación rigurosa requiere validación cruzada temporal y repetición con distintas semillas y activos.

C1

Fundamento teórico

$Q(a)/N(a)$ es el estimador de Monte Carlo aplicado a los rollouts. Converge c.s. por la LLN y el error decae $\mathcal{O}(N^{-1/2})$.

C2

Resultado experimental

ROI $\approx +240\%$ vs. $+100\%$ B&H · drawdown -10% vs. -75% · Sharpe 1,56 vs. 1,93.

C3

Política emergente

MCTS aprendió una política **todo-o-nada**. Esto sugiere que, bajo una recompensa relativa a B&H, las posiciones intermedias no aportan ventaja sistemática.

NO !!!Posibles extensiones

Extensiones del modelo

- **GBM multivariante:** cartera de varios activos con correlaciones (Cholesky)
- **Modelo de Merton:** GBM + saltos de Poisson para capturar *fat tails*
- **Costes de transacción:** penalización $\propto |\Delta \text{posición}|$

Extensiones del método

- **Reducción de varianza:** quasi-Monte Carlo (Sobol, Halton) $\rightarrow$ tasa $\mathcal{O}(n^{-1})$
- **Criterio de parada adaptativo:** detener cuando $\sigma(a)/\sqrt{N(a)} \leq \varepsilon$
- **Optimización de hiperparámetros:** búsqueda en cuadrícula con validación cruzada temporal

Próxima sección (trabajo futuro)

Otras aplicaciones del MCTS más allá del trading financiero: juegos de tablero (Go, ajedrez), planificación robótica, diseño de fármacos, optimización combinatoria...

Gracias por la atención

Carlos Ruiz Navarro

Métodos Numéricos · Universitat de València

Código disponible en:

`mcts_simple_TSLA.py`
(carpeta `mcts_activos/mcts_simple_TSLA/`)